一、Spark配置

1. 单机模式

1.1 下载Anaconda3

下载 Hbase 2.5.6：

```
wget https://repo.anaconda.com/archive/Anaconda3-2021.11-Linux-x86_64.sh
```

解压安装包Anaconda3-5.1.0-Linux-x86_64.sh至路径 /home/Lsc：

```
sudo tar -zxf ~/Anaconda3-2021.11-Linux-x86_64.sh -C /home/Lsc
```

安装Anaconda3：

```
sh ./Anaconda3-2021.11-Linux-x86_64.sh
```

接着然后一直回车然后空格，等出现接受许可界面，输入`yes`接收许可。

1.2 配置文件

配置国内源：

```
sudo vim ~/.condarc
```

追加以下内容：

```
channels:
  - defaults
show_channel_urls: true
default_channels:
  - https://mirrors.tuna.tsinghua.edu.cn/anaconda/pkgs/main
  - https://mirrors.tuna.tsinghua.edu.cn/anaconda/pkgs/r
  - https://mirrors.tuna.tsinghua.edu.cn/anaconda/pkgs/msys2
custom_channels:
  conda-forge: https://mirrors.tuna.tsinghua.edu.cn/anaconda/cloud
  msys2: https://mirrors.tuna.tsinghua.edu.cn/anaconda/cloud
  bioconda: https://mirrors.tuna.tsinghua.edu.cn/anaconda/cloud
  menpo: https://mirrors.tuna.tsinghua.edu.cn/anaconda/cloud
  pytorch: https://mirrors.tuna.tsinghua.edu.cn/anaconda/cloud
  simpleitk: https://mirrors.tuna.tsinghua.edu.cn/anaconda/cloud
```

创建pyspark环境:

```
conda create -n pyspark python=3.6  # 基于python3.6创建pyspark虚拟环境
conda activate pyspark      # 激活（切换）到pyspark虚拟环境
```

在pyspark环境中使用pip下载pyhive、pyspark、jieba包：

```
pip install pyspark==2.4.0 jieba pyhive -i
https://pypi.tuna.tsinghua.edu.cn/simple
```

1.3 Spark Local模式搭建

下载 spark-2.4.8，解压安装包spark-2.4.8-bin-without-hadoop至路径 /home/Lsc：

```
sudo tar -zxf ~/spark-2.4.8-bin-without-hadoop -C /home/Lsc
```

重命名：

```
mv spark-2.4.8-bin-without-hadoop/ spark-2.4.8
```

配置环境变量：

`vi ~/.bashrc` 修改 `.bashrc` 文件，在文件末尾追加：

```
# 默认启动pyspark虚拟环境
conda activate pyspark

# JAVA_HOME
export JAVA_HOME=/home/Lsc/jdk1.8.0_381
# PYSPARK_PYTHON
export PYSPARK_PYTHON=/home/Lsc/anaconda3/envs/pyspark/bin/python
export PATH=$JAVA_HOME/bin:$PATH
export SPARK_HOME=/home/Lsc/spark
export PATH=$SPARK_HOME/bin:$PATH
```

配置 `/etc/profile`，文件末尾追加：

```
export SPARK_HOME=/home/Lsc/spark-2.4.8
# HADOOP_CONF_DIR
export HADOOP_CONF_DIR=$HADOOP_HOME/home/Lsc/hadoop-3.3.6
# PYSPARK_PYTHON
export PYSPARK_PYTHON=/home/Lsc/anaconda3/envs/pyspark/bin/python
export
PATH=$JAVA_HOME/bin:$HADOOP_HOME/bin:$HADOOP_HOME/sbin:$SPARK_HOME/bin:$PATH
```

使环境变量文件立即生效：

```
source /etc/profile
source ~/.bashrc
```

配置spark-env.sh：

```
cd /opt/spark-2.4.0/conf
cp spark-env.sh.template spark-env.sh
```

在该文件最后追加以下内容：

```
export JAVA_HOME=/home/Lsc/jdk1.8.0_381
export SPARK_DIST_CLASSPATH=$(/home/Lsc/hadoop-3.3.6/bin/hadoop classpath)
```

验证Spark是否安装成功：

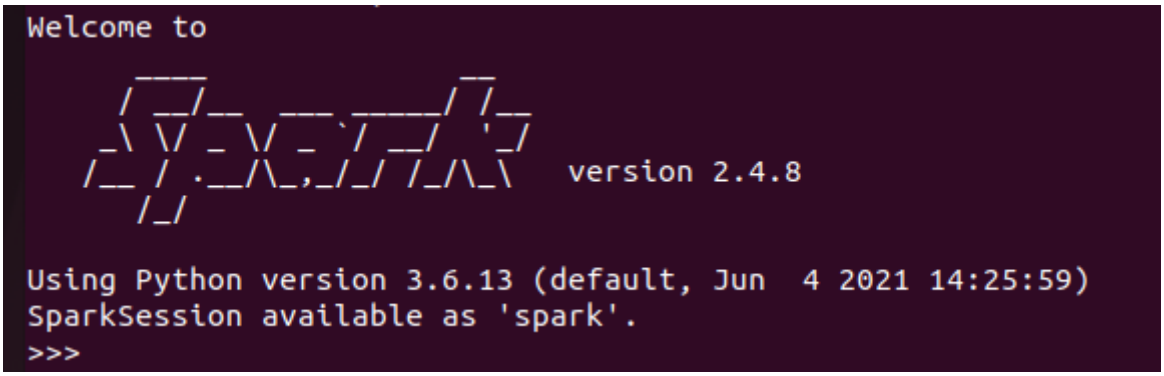

可见spark可以正常开启

WebUI截图：

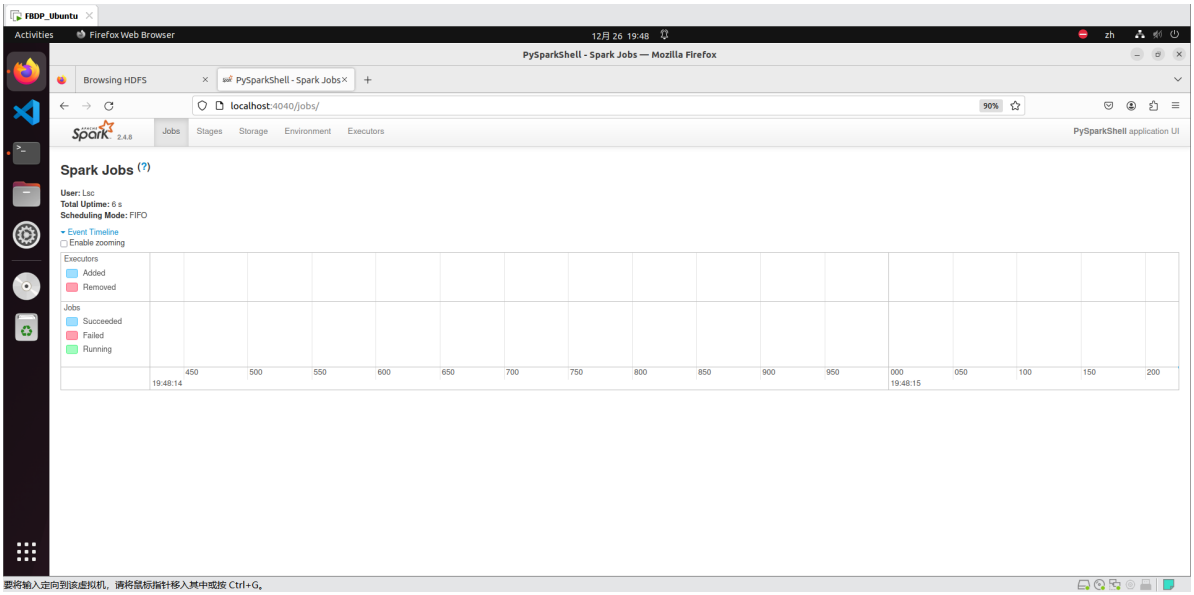

1.4 配置Jupyter Notebook

Jupyter notebook是一个很好的数据交互式工具，以下是具体配置步骤：

1. **激活 `pyspark` 环境**：

   打开终端，运行以下命令来激活 `pyspark` 环境：

   ```
   conda activate pyspark
   ```

2. **安装Jupyter**：

   ```
   conda install jupyter
   ```

   运行 `jupyter notebook --version` 判断是否安装成功

3. **配置jupyter notebook根目录**：
   安装完Jupyter运行后发现根目录为一个陌生的目录，并不方便使用，需要配置jupyter notebook每次打开的根目录，在激活`pyspark`的环境下运行如下命令：

   ```
   jupyter notebook --generate-config
   ```

   生成配置文件，去给出的文件地址：

```
/home/Lsc/.jupyter\jupyter_notebook_config.py
```

打开jupyter_notebook_config.py文件，修改配置文件：

```
将 #c.NotebookApp.notebook_dir = '' 改为
c.NotebookApp.notebook_dir = '/home/Lsc'
```

默认情况下，Jupyter Notebook 只能从启动服务器的机器上访问，通过如下设置启用远程访问：

```
pythonCopy codec.NotebookApp.ip = '0.0.0.0'  # 允许任何IP访问
c.NotebookApp.open_browser = False  # 不自动打开浏览器
```

4. **运行jupyter notebook**：
   在pyspark环境下执行`jupyter notebook`开启：

5. **检验jupyter notebook是否连接spark**：
   创建一个新的Notebook，选择pyspark环境的内核，运行Spark测试代码以确认一切正常
   这段代码创建了一个简单的 Spark DataFrame，包含两列（id 和 label）和两行数据，然后使用 show() 方法将其内容打印出来：

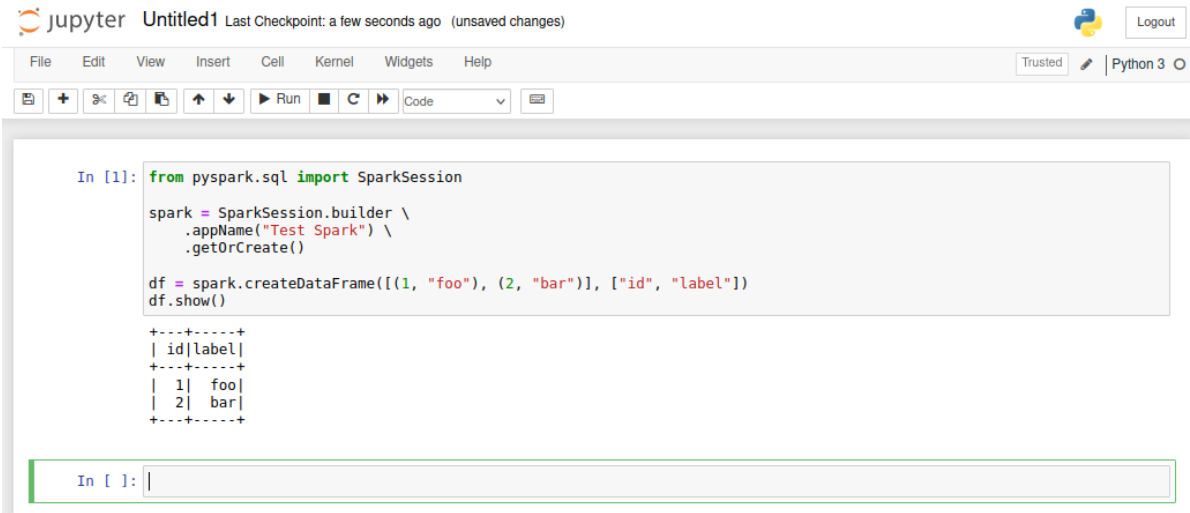

可见PySpark环境中测试代码输出结果正常，Spark环境正确配置，且jupyter 已成功连接spark。

二、银行贷款违约预测任务

1. 任务一

1.1 编写 Spark 程序，统计application_data.csv中所有用户的贷款金额AMT_CREDIT 的分布情况，以 10000 元为区间进行输出：

python代码如下：

```
from pyspark.sql import SparkSession
from pyspark.sql.functions import col, floor

# 创建 SparkSession
spark = SparkSession.builder.appName("LoanAmountDistribution").getOrCreate()

# 读取 CSV 文件
df = spark.read.csv("file:///home/Lsc/application_data.csv", header=True,
inferSchema=True)

# 选择并处理贷款金额列
df = df.withColumn("AMT_CREDIT", col("AMT_CREDIT").cast("double"))  # 确保列为浮点
型
df = df.withColumn("Credit_Range", floor(col("AMT_CREDIT") / 10000) * 10000)

# 计算每个区间的贷款金额分布
distribution = df.groupBy("Credit_Range").count()

# 格式化输出
formatted_output = distribution.rdd.map(lambda x: ((x[0], x[0] + 10000), x[1]))
# 对结果进行排序
sorted_output = formatted_output.sortBy(lambda x: x[0])

# 重分区到一个分区
single_partition_rdd = sorted_output.coalesce(1)
sorted_output.collect()
# 保存到文本文件
output_path = "file:///home/Lsc/FBDP_homework/homework4/output1-1"
single_partition_rdd.saveAsTextFile(output_path)

# 重分区到一个分区
single_partition_rdd = sorted_output.coalesce(1)

# 停止 Spark Session
spark.stop()
```

输出结果保存在文件`output1-1`之中，下面给出部分结果：

```
((40000, 50000), 561)
((50000, 60000), 891)
((60000, 70000), 719)
((70000, 80000), 1226)
((80000, 90000), 668)
((90000, 100000), 1939)
((100000, 110000), 1871)
((110000, 120000), 1930)
((120000, 130000), 1323)
((130000, 140000), 4792)
((140000, 150000), 2239)
((150000, 160000), 3653)
((160000, 170000), 1919)
((170000, 180000), 2131)
```

1.2 编写Spark程序，统计application_data.csv中客户贷款金额AMT_CREDIT比客户收入AMT_INCOME_TOTAL差值最高和最低的各十条记录：

python代码如下：

```python
from pyspark.sql import SparkSession
from pyspark.sql.functions import col

# 初始化Spark会话
spark = SparkSession.builder.appName("LoanIncomeDifference").getOrCreate()

#读取 CSV 文件
df = spark.read.csv("file:///home/Lsc/application_data.csv", header=True,
inferSchema=True)

# 计算差值
df = df.withColumn("Difference", col("AMT_CREDIT") - col("AMT_INCOME_TOTAL"))

# 获取差值最高的十条记录
top_10_max_diff = df.orderBy(col("Difference").desc()).limit(10)

# 获取差值最低的十条记录
top_10_min_diff = df.orderBy(col("Difference")).limit(10)

# 输出结果
top_10_max_diff.select("SK_ID_CURR", "NAME_CONTRACT_TYPE", "AMT_CREDIT",
"AMT_INCOME_TOTAL", "Difference").show()
top_10_min_diff.select("SK_ID_CURR", "NAME_CONTRACT_TYPE", "AMT_CREDIT",
"AMT_INCOME_TOTAL", "Difference").show()

# 关闭Spark会话
spark.stop()
```

客户贷款金额AMT_CREDIT比客户收入AMT_INCOME_TOTAL差值最高的十条记录：

```
+----------+------------------+----------+----------------+----------+
|SK_ID_CURR|NAME_CONTRACT_TYPE|AMT_CREDIT|AMT_INCOME_TOTAL|Difference|
+----------+------------------+----------+----------------+----------+
|    433294|        Cash loans| 4050000.0|        405000.0| 3645000.0|
|    210956|        Cash loans| 4031032.5|        430650.0| 3600382.5|
|    434170|        Cash loans| 4050000.0|        450000.0| 3600000.0|
|    315893|        Cash loans| 4027680.0|        458550.0| 3569130.0|
```

```
|    238431|        Cash loans| 3860019.0|        292050.0| 3567969.0|
|    240007|        Cash loans| 4050000.0|        587250.0| 3462750.0|
|    117337|        Cash loans| 4050000.0|        760846.5| 3289153.5|
|    120926|        Cash loans| 4050000.0|        783000.0| 3267000.0|
|    117085|        Cash loans| 3956274.0|        749331.0| 3206943.0|
|    228135|        Cash loans| 4050000.0|        864900.0| 3185100.0|
+----------+------------------+----------+----------------+----------+
```

客户贷款金额AMT_CREDIT比客户收入AMT_INCOME_TOTAL差值最低的十条记录：

```
+----------+------------------+----------+----------------+-------------+
|SK_ID_CURR|NAME_CONTRACT_TYPE|AMT_CREDIT|AMT_INCOME_TOTAL|   Difference|
+----------+------------------+----------+----------------+-------------+
|    114967|        Cash loans|  562491.0|          1.17E8|-1.16437509E8|
|    336147|        Cash loans|  675000.0|      1.800009E7|  -1.732509E7|
|    385674|        Cash loans| 1400503.5|          1.35E7|-1.20994965E7|
|    190160|        Cash loans| 1431531.0|       9000000.0|   -7568469.0|
|    252084|        Cash loans|  790830.0|       6750000.0|   -5959170.0|
|    337151|        Cash loans|  450000.0|       4500000.0|   -4050000.0|
|    317748|        Cash loans|  835380.0|       4500000.0|   -3664620.0|
|    310601|        Cash loans|  675000.0|       3950059.5|   -3275059.5|
|    432980|        Cash loans| 1755000.0|       4500000.0|   -2745000.0|
|    157471|        Cash loans|  953460.0|       3600000.0|   -2646540.0|
+----------+------------------+----------+----------------+-------------+
```

2. 任务二

2.1 统计所有男性客户（CODE_GENDER=M）的小孩个数（CNT_CHILDREN）类型占比情况：

python代码如下：

```python
from pyspark.sql import SparkSession
from pyspark.sql.functions import col, count, format_number

# 初始化Spark会话
spark = SparkSession.builder.appName("GenderChildrenAnalysis").getOrCreate()

#读取 CSV 文件
df = spark.read.csv("file:///home/Lsc/application_data.csv", header=True,
inferSchema=True)

# 过滤出男性客户
men_df = df.filter(df["CODE_GENDER"] == "M")
# 计算男性客户总数
total_men_count = men_df.count()

# 对 CNT_CHILDREN 进行分组并计算每组的数量
result = men_df.groupBy("CNT_CHILDREN").count()

# 计算每种小孩个数的占比并格式化为保留8位小数
result = result.withColumn("formatted_ratio", format_number((col("count") /
total_men_count), 8))

# 选择需要的列
result_df = result.select("CNT_CHILDREN", "count", "formatted_ratio")

# 按照 CNT_CHILDREN 升序排列
```

```
ordered_result_df = result_df.orderBy("CNT_CHILDREN")

# 显示结果
ordered_result_df.show()

# 关闭 SparkSession
spark.stop()
```

输出结果：

```
+------------+-----+---------------+
|CNT_CHILDREN|count|formatted_ratio|
+------------+-----+---------------+
|           0|70318|     0.66931914|
|           1|22660|     0.21568833|
|           2|10413|     0.09911573|
|           3| 1446|     0.01376369|
|           4|  170|     0.00161814|
|           5|   33|     0.00031411|
|           6|   11|     0.00010470|
|           7|    4|     0.00003807|
|           8|    1|     0.00000952|
|           9|    1|     0.00000952|
|          11|    1|     0.00000952|
|          14|    1|     0.00000952|
+------------+-----+---------------+
```

2.2 统计每个客户出生以来每天的平均收入（avg_income）=总收入（AMT_INCOME_TOTAL）/出生天数（DAYS_BIRTH），统计每日收入大于1的客户，并按照从大到小排序，保存为csv：

python代码如下：

```
from pyspark.sql import SparkSession
from pyspark.sql.functions import abs, col, format_number

# 初始化Spark会话
spark = SparkSession.builder.appName("AverageDailyIncome").getOrCreate()

# 读取 CSV 文件
df = spark.read.csv("file:///home/Lsc/application_data.csv", header=True,
inferSchema=True)

# 计算每天的平均收入，并使用format_number保留五位小数，注意DAYS_BIRTH是负值，需要取绝对值
#df = df.withColumn("avg_income", format_number(col("AMT_INCOME_TOTAL") /
abs(col("DAYS_BIRTH")), 5))
df = df.withColumn("DAYS_BIRTH_ABS", abs(col("DAYS_BIRTH")))
df = df.withColumn("avg_income", col("AMT_INCOME_TOTAL") /
col("DAYS_BIRTH_ABS"))
# 筛选出每日收入大于1的客户
filtered_df = df.filter(col("avg_income") > 1)
# 按照每日平均收入降序排序
sorted_df = filtered_df.orderBy(col("avg_income").desc())

# 选择需要的列
df_final = sorted_df.select("SK_ID_CURR", "avg_income")

# 将结果汇总到一个csv文件中
```

```
df_final.coalesce(1).write.csv("file:///home/Lsc/22", header=True)

# 关闭Spark会话
spark.stop()
```

输出结果：

	Standard	Standard
1	SK_ID_CURR	avg_income
2	114967	9274.673008323425
3	336147	1146.2105196128375
4	385674	996.2364401151207
5	190160	547.945205479452
6	219563	417.51716459454445
7	310601	373.63408059023834
8	157471	360.4325190228274

3. 任务三

根据给定的数据集，基于Spark MLlib 或者Spark ML编写程序对贷款是否违约进行分类，并评估实验结果的准确率。该任务可视为一个“二分类”任务，因为数据集只存在两种情况，违约（Class=1）和其他（Class=0）。

按照8：2的比例将数据集application_data.csv随机拆分成训练集和测试集。最后评估模型的性能，评估指标为accuracy、f1-score。

这部分内容写在了jupyter notebook内，详情见文件

1. MLP (多层感知器)
    - 准确率 (Accuracy): 0.9143
    - 召回率 (Recall): 0.8915
    - F1 分数 (F1 Score): 0.9027
2. GBT 分类器 (Gradient Boosting Trees Classifier)
    - 准确率 (Accuracy): 0.9152
    - 召回率 (Recall): 0.7737
    - F1 分数 (F1 Score): 0.8385
3. 随机森林 (Random Forest)
    - 准确率 (Accuracy): 0.8793
    - 召回率 (Recall): 0.7999
    - F1 分数 (F1 Score): 0.8377
4. 逻辑回归 (Logistic Regression)
    - 准确率 (Accuracy): 0.7531
    - 召回率 (Recall): 0.7726
    - F1 分数 (F1 Score): 0.7627

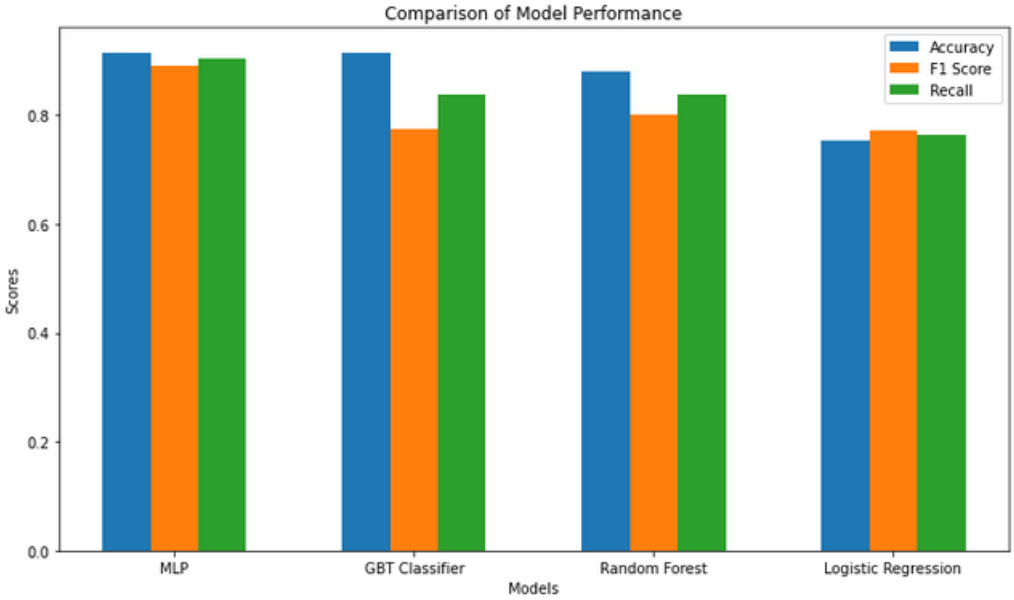

三、遇到的问题

1.虚拟机磁盘空间不足

- 点击编辑虚拟机设置-> 硬盘-> 扩展（此处如果扩展不可点，需要删除所有快照）：

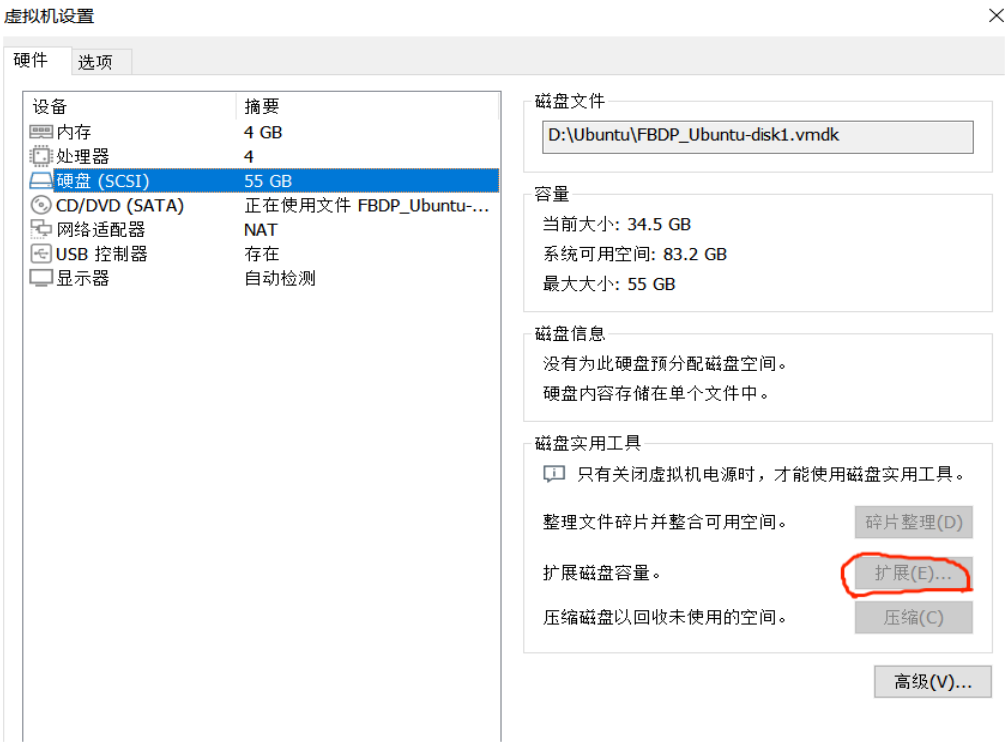

- 弹出页面填写要增加到多少内存->扩展，等待完成即可:

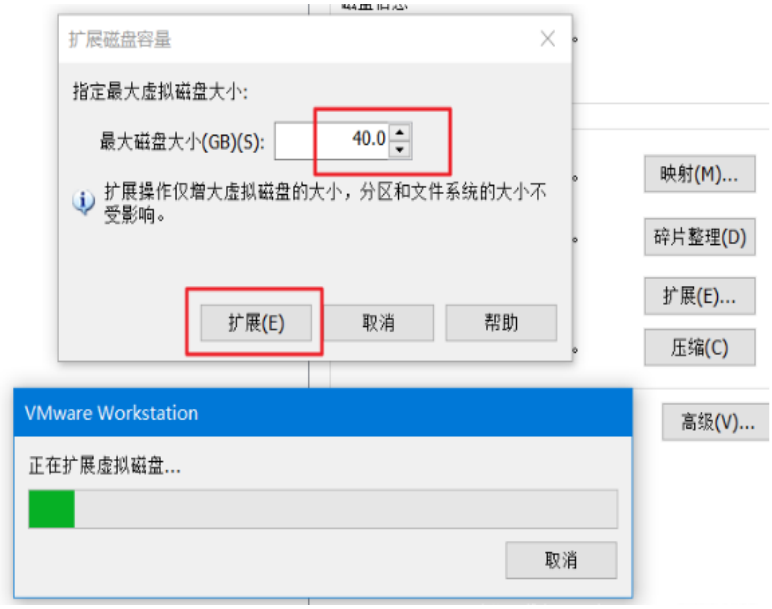

- 开机后进入recover模式，删除日志文件，腾出空间，以便可以成功安装gparted:
- 点击**开启虚拟机**时，按住**shift 键**，用方向键选择 `[Ubuntu](https://so.csdn.net/so/search?q=Ubuntu&spm=1001.2101.3001.7020) 高级选项` -> **回车**进入 -> 选择 `recover mode` -> **回车**进入:

```
df -h                # 查看磁盘使用情况，可看到 sda1 使用率为 100%
cd /var/log/cups     # 进入文件夹
ls -lhS              # 将文件以从大到小顺序展现

rm -rf error_log     # 删除没用的日志文件
ls -lhS              # 再次查看
df -h                # 再次查看使用率为93%

reboot               # 重启进入系统
```

```
root@hl-PC:~#
root@hl-PC:~#
root@hl-PC:~# df -h
Filesystem      Size  Used Avail Use% Mounted on
udev            956M     0  956M   0% /dev
tmpfs           198M  3.4M  194M   2% /run
/dev/sda1        19G   19G     0 100% /
tmpfs           986M     0  986M   0% /dev/shm
tmpfs           5.0M  4.0K  5.0M   1% /run/lock
tmpfs           986M     0  986M   0% /sys/fs/cgroup
root@hl-PC:~# cd /var/log/cups
root@hl-PC:/var/log/cups# ls -lhS
total 7.7G
-rw-r----- 1 root adm 6.3G May 30 20:26 error_log
-rw-r----- 1 root adm 1.5G May 30 18:23 error_log.1
-rw-r----- 1 root adm 2.2K May 30 18:12 access_log.1
-rw-r----- 1 root adm  277 May 20 17:01 access_log.4.gz
-rw-r----- 1 root adm  242 Apr 14 07:38 access_log.6.gz
-rw-r----- 1 root adm  240 May 28 19:11 access_log.2.gz
-rw-r----- 1 root adm  225 May 18 09:47 access_log.5.gz
-rw-r----- 1 root adm  200 May 21 07:35 access_log.3.gz
-rw-r----- 1 root adm  109 May 19 10:14 error_log.2.gz
-rw-r----- 1 root adm    0 May 30 18:21 access_log
-rw-r----- 1 root adm    0 Apr  9 09:59 page_log
root@hl-PC:/var/log/cups#
```

- 安装 gparted，重新分配内存

```
sudo apt-get install gparted  # 安装
sudo gparted   #启动
```

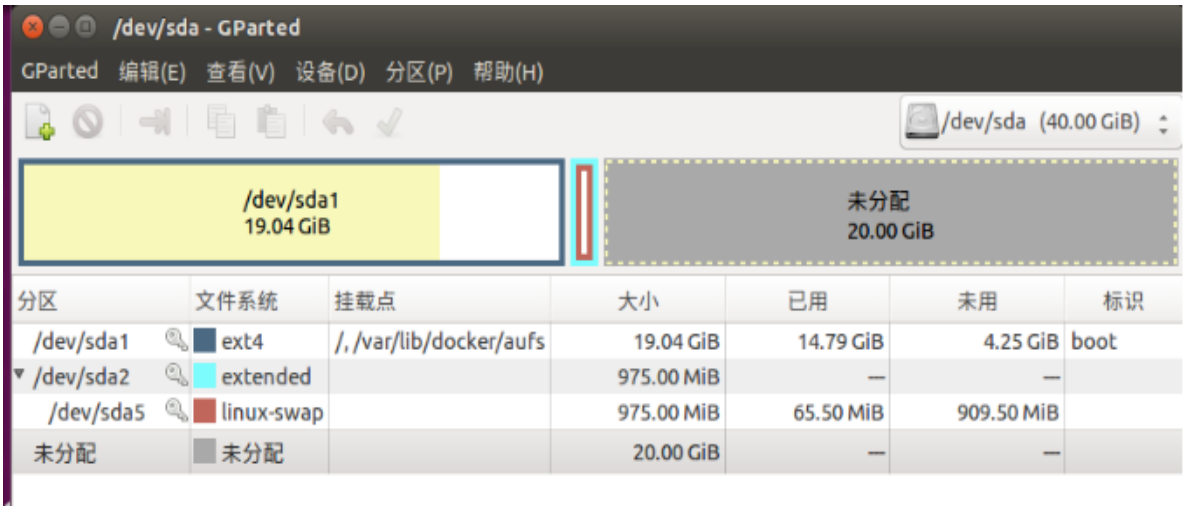

- 重新调整分区:

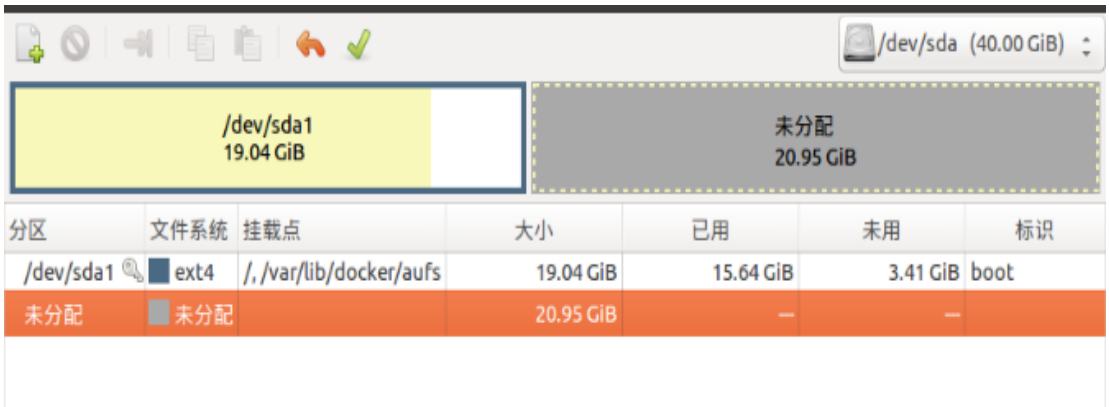

- **最终成功扩展虚拟机磁盘空间**

2.无法用conda命令新建python环境

用conda命令`conda create -n pyspark python=3.6`新建python环境时，一直报错:

```
CondaHTTPError: HTTP 000 CONNECTION FAILED for url
An HTTP error occurred when trying to retrieve this URL
```

一开始以为是源的问题，更换各种形式的源（比如清华源、中科大源、阿里云等）之后仍报错
更换https为http仍然无法解决问题，开始反思是不是走了**代理**:

```
(base) Lsc@Lsc-virtual-machine:~$ export | grep -i prox
declare -x ALL_PROXY="socks://192.168.126.1:7890/"
declare -x FTP_PROXY="http://192.168.126.1:7890/"
declare -x HTTPS_PROXY="http://192.168.126.1:7890/"
declare -x HTTP_PROXY="http://192.168.126.1:7890/"
declare -x NO_PROXY="localhost,127.0.0.0/8,::1"
declare -x all_proxy="socks://192.168.126.1:7890/"
declare -x ftp_proxy="http://192.168.126.1:7890/"
declare -x http_proxy="http://192.168.126.1:7890/"
declare -x https_proxy="http://192.168.126.1:7890/"
declare -x no_proxy="localhost,127.0.0.0/8,::1"
```

为了测试是否是代理设置导致的问题，临时禁用代理设置:

```
unset ALL_PROXY FTP_PROXY HTTPS_PROXY HTTP_PROXY NO_PROXY all_proxy ftp_proxy
http_proxy https_proxy no_proxy
```

然后再次尝试使用 Conda命令，实现成功下载。

分析可能的原因如下:

- 代理服务器配置：
代理配置指向 192.168.126.1 端口 7890，如果此代理服务器不正确配置、不可访问，或不允许访问 Conda 的服务器，则会导致下载失败。
- 不一致的代理类型：
环境变量中设置了两种类型的代理：HTTP (http://192.168.126.1:7890/) 和 SOCKS (socks://192.168.126.1:7890/)，这可能导致某些应用或服务无法正确解析或使用这些代理设置。

四、总结收获

本实验围绕银行贷款违约预测，使用Spark处理和分析约30万条贷款数据。目标是理解和预测贷款违约风险，增进对金融数据分析的认识。下面是我的总结与反思：

1. **数据处理和统计分析**：
    - 学习了如何使用Spark进行基本的数据处理，如贷款金额分布的计算。
    - 掌握了关键财务指标的分析方法。
2. **Spark SQL应用**：
    - 理解了在大数据环境下使用Spark SQL进行数据查询和分析的方法。
    - 掌握了如何统计特定的数据特征。
3. **机器学习模型训练**：
    - 通过构建和评估机器学习模型，增强了对Spark MLlib和Spark ML的理解。
    - 学习了如何处理、分析数据，并应用于实际的分类模型中。
4. **实验挑战与解决方案**：
    - 在数据处理过程中遇到的挑战主要集中在数据的清洗和预处理上。
    - 通过实验学会了如何针对具体问题调整数据处理策略。

本次实验使用Spark进行数据处理和分析，对银行贷款违约分类任务有了更深刻的理解。后续需要深入学习Spark的高级功能，探索更多机器学习算法在金融风险评估中的应用。